

Billy

Sous le capot : méthodes, sources & moteur de dialogue

Billy — document de référence

Avertissement. Brouillon de travail, non validé par des professionnels.

À qui s'adresse ce document ? À toi (Ben), aux professionnels qui valident, et à toute personne qui doit comprendre

d'où vient ce que Billy dit

Il répond précisément à deux peurs légitimes :

pourquoi il ne peut structuellement pas déraiper

• **Une hallucination de l'IA pourrait déclarer qu'une phrase est OK alors qu'elle ne l'est pas.** →

Voir

• **« Je ne sais pas ce qu'il y a sous le capot du moteur de dialogue. »** → Voir

Réponse courte :

\$3 et \$4

ce n'est pas l'IA qui décide si une phrase est OK.

On décode le pipeline ligne par ligne, fichier par fichier.

1. L'idée-force en une page

Billy parle à un enfant de 2-5 ans potentiellement victime de violence. Dans ce contexte, **une seule phrase mal formulée peut nuire à l'enfant et détruire la valeur judiciaire de sa parole**

. On ne peut donc pas se permettre « 99 % de phrases correctes ». Il faut

0 fuite

Or aucune IA générative ne garantit 0 fuite : par construction, un modèle de langage *invente* du texte, et peut donc inventer une mauvaise phrase.

La décision de fond du projet est donc de ne JAMAIS laisser une IA rédiger ce que Billy dit à l'enfant.

À la place, deux principes :

Principe —

Conséquence concrète

▪ Répertoire fermé —

Tout ce que Billy peut prononcer est écrit à l'avance, dans un fichier (`script-billy.json`

), et

validé/signé par les professionnels

. L'espace des phrases possibles est

fini et entièrement testable

▪ L'IA choisit, elle ne rédige pas —

Le modèle de langage (Claude) sert seulement à

choisir

quelle phrase pré-validée jouer ensuite — il rend un

identifiant

, jamais du texte. Et même ce choix

repassse par un filtre déterministe

avant d'être prononcé.

C'est ce qu'on appelle l'**Option A**

(décision de cadrage du 21/06/2026) et l'approche

« LLM-sélecteur »

(et non « LLM libre »). Le veto « pas de LLM qui génère du texte face à l'enfant »

n'est pas levé

et ne le sera pas en V1.

2. Les méthodes intégrées — d'où vient la posture

La posture de Billy n'est pas inventée. Chaque règle vient d'une source reconnue. Voici la **traçabilité méthode**
→ **source** → **endroit dans le code/contenu**

2.1 Le socle : le protocole NICHD

Le NICHD

(

National Institute of Child Health and Human Development

) est le protocole d'audition d'enfants le plus validé scientifiquement au monde. Principe :

plus une question est ouverte, plus la réponse est fiable ; plus elle est fermée/suggestive, plus la parole

est contaminée et inexploitable.

On en a tiré **deux choses concrètes**

:

(a) La hiérarchie des questions — codée comme une règle de tri du plus fiable au moins fiable (docs/protocole-entretien-NICHD.md

) :

- **Invitations** (« Raconte-moi... », « Et après ? ») ☐ privilégiées
- **Relances sur les mots DÉJÀ dits par l'enfant** (« Tu as parlé de [son mot] , raconte-moi ça ») ☐
- Questions ouvertes de précision (qui/quoi/où, sans suggérer) ☐ avec prudence
- Questions fermées / orientées / suggestives ☐ **interdites par construction**

(b) Les 7 phases de l'entretien — qui structurent **directement**

le déroulé de Billy. Le fichier
public/content/script-billy.json
a exactement ces phases :

Phase NICHD —

Phase dans le script

Ce que Billy y fait

- **Mise en confiance** —
P1
Accueil & transparence
—
« Je suis un personnage, pas une vraie personne »
- **(droit de l'enfant)** —
P2
Droit d'arrêter
—
« Si tu veux qu'on s'arrête, tu décides »
- **Règles de base** —
P3
Règles de base
—
« Si je me trompe, corrige-moi », « tu peux dire je ne sais pas », « on ne devine pas »
- **Entraînement au récit épisodique** —
P4
Récit d'un sujet neutre
—
« Raconte-moi ta journée d'hier » (entraîne le récit libre **avant** tout sujet sensible)
- **Transition vers le sujet** —
P5
Ouverture la plus neutre possible
—
« Y a-t-il quelque chose qui t'embête et dont tu voudrais parler ? » —
Billy n'introduit jamais le thème de l'abus
- **Récit libre / suivi ouvert** —
(relances ouvertes)
—
Billy n'intervient qu'avec des invitations
- **Clôture & réconfort** —
P7
Clôture + orientation
—
Remercie sans valider le contenu, passe le relais à l'humain
- **(cas signal)** —
P6
Révélation / signal

Lien direct : les phases du protocole sont les phases
du JSON, vérifiables avec la page
/atelier.html

(« Cahier de la posture » : chaque phrase + son intention + sa source).

2.2 Les sources qui complètent le NICHHD

Le NICHHD dit *comment questionner*

. D'autres sources cadrent

le fond, l'âge, l'escalade et le réconfort

. Toutes sont citées verbatim dans

docs/posture-reference_V1.md !' V4.md

:

Source —

Ce qu'on en a tiré

■ CIIVISE (livret « Mélissa et les autres », rapport 2023)

Posture d'accueil, « je te crois », « ce n'est pas ta faute » ; ne pas faire répéter

■ MIPROF / arretonslesviolences —

Repères d'orientation et de signalement

■ **proteger-nos-enfants.fr,** **Guide parents VSM (Ville de Paris)**

Posture parent, pièges à éviter (ne pas promettre le secret, ne pas confronter)

■ **Dr Salmona — Mémoire Traumatique et Victimologie** —

Compréhension du psychotraumatisme, non-minimisation

■ **CRIAVS** —

Comportements sexuels normaux/inquiétants

par âge

(cible 2-5 ans)

■ **Barnahus / PROMISE** —

Modèle « un intervenant + un observateur passif » → 2^e téléphone (V2)

■ **NSPCC / RAINN / Stop It Now / Darkness to Light** —

Bonnes pratiques internationales de prévention

2.3 Pourquoi ces sources, et ce qu'elles apportent (en grandes lignes)

On ne choisit pas une source parce qu'elle « va dans notre sens », mais parce qu'elle **fait autorité**

: protocole validé scientifiquement, institution publique mandatée, ou clinicien de référence. Voici, pour chaque source,

pourquoi on peut s'y fier

et

ce qu'elle apporte

. Le détail « quelle source → quelle ligne de code » est dans
docs/wiki-sources-billy.md

; ici, c'est la vue d'ensemble.

□ **Les protocoles d'audition — le squelette**

• **NICHHD 2021**

(National Institute of Child Health and Human Development, USA)

—
la référence mondiale.

C'est le protocole d'audition d'enfants

le plus étudié et le plus validé empiriquement

(des centaines d'études sur des entretiens réels). Pourquoi pertinent : il ne donne pas un avis, il donne une

méthode prouvée

pour faire parler un enfant

sans contaminer sa parole

.

Apport :

les 7 phases d'une séance, la hiérarchie des questions (ouvert > fermé), les « règles de base », et la règle d'or « ne jamais nommer en premier ». C'est le

squelette entier

de Billy.

- **Barnahus / PROMISE**

(standards de qualité européens)

— le modèle institutionnel de la « maison des enfants », adopté dans toute l'Europe. Pourquoi pertinent : il fixe

comment organiser

la prise en charge sans faire répéter l'enfant.

Apport :

le principe « un intervenant + des observateurs passifs » (→ 2^e téléphone en lecture seule) et « entretien unique » (→ ne pas faire répéter).

- **ABE — Achieving Best Evidence (UK)** — référence judiciaire britannique,

converge

avec NICHD sur le questionnement gradué. Sert de

contre-vérification

: deux protocoles indépendants disent la même chose → confiance accrue.

- **L'institutionnel français — la posture et l'orientation**

- **CIIVISE**

(Commission Indépendante sur l'Inceste et les Violences Sexuelles faites aux Enfants)

—

commission publique française

, audition de dizaines de milliers de victimes. Pourquoi pertinent : c'est la

doctrine officielle française

récente et faisant autorité.

Apport :

le principe fondateur de l'Option A —

« signaler n'est pas enquêter »

— et les trois piliers

croire / rassurer-déculpabiliser / orienter

. C'est ce qui justifie que Billy

repère et oriente sans recueillir le récit sensible

.

- **MIPROF / arretonslesviolences.gouv.fr** —

mission interministérielle

officielle.

Apport :

confirme les réflexes (écouter, ne pas enquêter, orienter) et le

circuit de signalement

français.

- **119 — Allô Enfance en Danger** — le

service public national

de référence (gratuit, confidentiel, 24/7).

Apport :

le

réflexe d'orientation principal

imposé dès tout signal.

- **protege-nos-enfants.fr &**

Guide parents VSM (Ville de Paris)

— ressources publiques

très opérationnelles

(phrases exactes, signaux par âge).

Apport :

les

verbatim

des bonnes réactions (« je te crois »), la liste des pièges, les

10 signaux d'alerte

, et le

cas institutionnel

(adulte d'une structure mis en cause → art. 40 CPP).

- **CN2R**
(*Centre National de Ressources et de Résilience*)
&
La Voix de l'Enfant (UAPED)
— références françaises sur l'accueil de la parole et la
destination de prise en charge
.
Apport :
la posture d'accueil et l'ancrage des
UAPED
dans l'orientation.
- **Les repères de développement — pour NE PAS sur-alerter**
- **CRIAVS Île-de-France**
(*Centre Ressource pour les Intervenants auprès des Auteurs de Violences Sexuelles*)
— expertise clinique sur les comportements sexuels par âge. Pourquoi pertinent : sans ce repère, on
sur-alerterait
sur des comportements
normaux
pour l'âge.
Apport :
les critères qui font basculer « normal → préoccupant » (contrainte, écart d'âge, secret, compulsivité...) →
réduit les faux positifs
de la détection. Précision capitale : explorer l'identité de genre est
normal
et
ne doit pas
être codé en signal.
- **La clinique du psychotraumatisme**
- **Dr Muriel Salmona — Mémoire Traumatique et Victimologie —**
psychiatre, autorité française
sur le psychotraumatisme.
Apport décisif et contre-intuitif :
un enfant gravement traumatisé
peut sembler aller bien
(récit froid, dissocié) → il faut s'inquiéter
d'avantage
, pas moins. D'où deux règles fortes : ne
jamais
présenter un récit calme comme rassurant dans le rapport, et
ne jamais nommer l'auteur par un terme affectif
(« ton papa »...) — règle codée dans le filtre.
- **L'international — ce qui manque côté français**
- **NSPCC (UK), RAINN (US), Stop It Now, Darkness to Light, UNICEF** — grandes organisations de
protection de l'enfance.
Apport :

NSPCC
→ « plusieurs petites conversations valent mieux qu'un grand entretien » (fonde le
multi-séances V2
) et « la révélation est souvent indirecte » ;
RAINN
→ ne pas lire le calme comme une preuve que rien ne s'est passé (converge avec Salmona) ;
UNICEF
→ se mettre à hauteur de l'enfant.
- **Le cadre légal — l'ossature de l'orientation**
- **Code de procédure pénale / Code pénal —**
art. 40 CPP
(signalement au procureur),
art. 434-1 / 434-3 CP
(non-dénonciation / non-assistance).
Apport :
l'

obligation

d'orienter, le principe « l'accord du mineur n'est pas nécessaire », et « si les détenteurs de l'autorité parentale sont mis en cause, ne pas les informer » → branche d'escalade institutionnelle (cas critique pour la cible 2-5 ans).

Le fil rouge des sources : elles

convergent toutes

vers la même posture (ouvrir, ne pas suggérer, croire, orienter). Cette

convergence de sources indépendantes

— un protocole américain, une commission française, une clinicienne, des ONG internationales — est en soi un gage de solidité : ce n'est pas une opinion, c'est un consensus.

Limite assumée :

cette compilation reste un

brouillon de travail.

; aucune source ne vaut

2.4 Ce que ces méthodes deviennent dans le code

Chaque règle de méthode est devenue une **règle de blocage déterministe**

caution professionnelle

dans lequel que de vrais experts n'ont pas validé le répertoire (cf. [source pour validation professionnelle](#)).

. C'est la traduction « méthode → garde-fou exécutable » :

Règle de méthode (NICHD / sources) —

ruleId

dans le code

Ce qui est bloqué

- **Ne jamais nommer un acte / une partie du corps** —

TABOO_LEXICON

« il t'a touché le zizi ? »

- **Ne jamais désigner un auteur** —

NAME_PERPETRATOR

« est-ce que papa... »

- **Ne jamais introduire un lieu** —

NAME_PLACE

« c'était dans la chambre ? »

- **Questions ouvertes uniquement** —

CLOSED_YESNO

« tu avais peur ? »

- **Pas de tag de confirmation** —

SUGGESTIVE_TAG

« ..., c'est bien ça ? »

- **Ne pas présupposer un fait** —

PRESUPPOSITION

« quand il t'a fait ça... »

- **Pas de choix forcé** —

FORCED_CHOICE

« c'était le jour ou la nuit ? »

- **Aucune pression / insistance** —

PRESSURE

« tu es sûr ? », « réfléchis bien »

- **Pas de récompense conditionnée** —

CONDITIONAL_REWARD

« si tu me dis, tu auras un bonbon »

- **Ne pas enrichir la parole de l'enfant** —

ENRICHED_REFORMULATION

« tu as parlé du garage » (jamais dit)

- **Ne pas imposer un vécu** —
EMOTIONAL_LABEL
—
« ça a dû te faire peur »
- **Ne pas promettre le secret** —
PROMISE_SECRET
—
« c'est notre secret »
- **Ne pas minimiser** —
MINIMIZE
—
« c'est pas si grave »
- **Pas de répétition d'une même question** —
REPEAT_QUESTION
—
(relance déjà posée)
- **Pas de mémoire/lien affectif simulé (multi-séances)** —
REINJECTION_PAST

AFFECTIVE_CONTINUITY
—
« la dernière fois tu m'avais dit... », « tu m'as manqué »

Ces deux dernières règles viennent du **red-team**

(
docs/redteam-rapport-V1.md

): on a attaqué Billy nous-mêmes pour trouver les trous, puis on les a bouchés.

3. Sous le capot — l'anatomie du moteur de dialogue

Trois fichiers font tout le travail. Comprends ces trois-là, tu comprends le moteur entier.

Fichier	Rôle
src/safety/antiSuggestion.js	LE JUGE. Code déterministe (regex + allow-list). Dit PASS ou BLOCK. NE CONTIENT AUCUNE IA. Ne peut pas halluciner.
src/conversation/selector.js	LE CHEF D'ORCHESTRE. Construit le menu de la phase, appelle l'IA pour choisir, puis VALIDE le choix via le Juge.
src/conversation/llm.js	L'AIGUILLEUR (optionnel). Appelle Claude pour qu'il CHOISISSE un id. Forcé à ne rendre qu'un choix structuré, jamais du texte.

3.1 Le Juge : `antiSuggestion.js` (le cœur de la confiance)

C'est le

fichier à comprendre. Il expose deux fonctions de décision, et

aucune n'est une IA

— ce sont des règles écrites à la main, donc

déterministes et reproductibles

:

- **`evaluate(texte, état)`** =
l'allow-list
(le rempart runtime). Verdict
PASS

uniquement si
le texte est
identique
à une réplique du répertoire signé (
APPROVED_RAW

'antiSuggestion.js:47
) , ou une « cued-invitation » dont le mot vient
prouvablement
de l'enfant.

Tout le reste = `BLOCK`.

- `audit(texte, état)` = les
15 règles anti-suggestion
(le lint / défense en profondeur). Passe le texte dans toutes les règles du §2.4, premier
BLOCK
gagne.

Pourquoi une allow-list et pas seulement une liste de règles ? (Décision clé issue du red-team, finding F-12.)

Une

liste noire

(« interdis ces formes ») ne peut jamais garantir

0 faux négatif

: il y aura toujours une formulation tordue qu'elle n'a pas prévue. Une

liste blanche

sur un espace

fini

(le répertoire signé), oui : ce qui n'est pas explicitement autorisé est refusé. C'est exactement pour ça que le répertoire est fermé.

Fail-closed partout : toute exception, tout doute, tout texte vide →

BLOCK

```
(  
antiSuggestion.js:113
```

```
:103
```

```
). On préfère
```

bloquer à tort

une phrase correcte (faux positif acceptable) plutôt que

laisser passer à tort

une phrase suggestive (faux négatif

inacceptable

).

3.2 Le Chef d'orchestre : `selector.js`

À chaque tour, c'est lui qui décide quelle est la prochaine phrase. Son cœur est la fonction `finalize()`

```
(  
selector.js:113
```

```
) —
```

le passage obligé

:

aucun

texte ne sort sans y passer. Voici sa logique, dans l'ordre :

- **Signal détecté ?** (détresse / révélation / danger) → on n'exécute
pas
un choix libre : on
impose
réassurance + clôture + orientation
119
, et on va en phase P7.
Le modèle ne pilote jamais la révélation
(
selector.js:121
).
• **Cued-invitation** (reprenre un mot de l'enfant) → le mot doit être
prouvablement
dans les mots dits par l'enfant
ET
repasser
`evaluate()`
→ sinon repli (
selector.js:130
).
• **Invitation ouverte** → doit appartenir à la liste des invitations neutres pré-validées
ET
passer
`audit()`

```
→ sinon repli (
selector.js:140
).
```

- **`say` (jouer une réplique du menu)** → l'id doit exister **dans le menu de la phase courante ET** la réplique doit passer `audit()`
→ sinon repli (selector.js:146).
- **Tout autre cas** → repli sur une invitation neutre pré-validée (« Et après ? »).

Le menu (
`buildMenu`

`'selector.js:35`

`)` ne contient

que

les répliques de la phase courante du script signé, et

exclut

les réactions de révélation (P6 n'est jamais offert au choix libre). C'est la

seule

liste où un id peut être choisi.

3.3 L'Aiguilleur : ``llm.js`` (et pourquoi il est inoffensif)

Quand une clé `ANTHROPIC_API_KEY`

est présente, Billy appelle Claude pour rendre l'échange plus vivant.

Mais le modèle est mis dans une cage :

- On le **force**
(
`tool_choice: { type: 'tool', name: 'choisir' }`

``llm.js:62`
) à appeler un seul outil,
`choisir`
, dont le schéma
n'a pas de champ texte libre
: il ne peut renvoyer qu'un
`action`
(
`say`
/
`cued_invitation`
/
`open`
) , un
`phraseId`
, un
`cuedWord`
(un mot de l'enfant), un
`signal`
, et une phase suivante (
``llm.js:16`
).
• **`temperature: 0`** (
``llm.js:58`
) : déterminisme maximal, pas de fantaisie.
• La **clé reste sur le serveur**
jamais exposée au navigateur (
``llm.js:46`
).
• En cas de **timeout / erreur / réseau / réponse non conforme**
→ la fonction renvoie
`null`
(
``llm.js:69`
) , et le moteur

bascule sur le repli déterministe

```
(
  selector.js:172
).
```

Autrement dit : **le modèle ne peut physiquement pas renvoyer une phrase à dire.**

Il ne peut renvoyer qu'un

bulletin de vote

(« je propose l'id P4-3 ») — et ce bulletin est ensuite

recompté par le Juge

avant toute parole.

4. Le trajet complet d'une phrase (end-to-end)

Voici, étape par étape, ce qui se passe entre « l'enfant a parlé » et « Billy répond ». Endpoint réel : POST /api/next

```
(
  src/server/index.js:80
).
```

```
L'enfant parle > STT (transcription dans le navigateur)
↓
POST /api/next { phaseId, history, childUtterance, childWords[], turnInPhase }
                  (childWords = mots RÉELLEMENT dits par l'enfant)
↓
selector.chooseNext()
  +-[clé IA présente]> llm.selectViaLLM() -- Claude CHOISIT un id (jamais du texte)
                        | temp 0, tool_choice forcé, timeout 4 s
                        ↓
                        décision structurée { action, phraseId?, cuedWord?, signal, nextPhase }
                        | (ou null si erreur/timeout)
  +-[pas de clé / null]> chooseDeterministic() -- choix mécanique, sans IA
                        ↓
  +----- selector.finalize() -----+
  | LE PASSAGE OBLIGÉ — quel que soit le chemin au-dessus : |
  | - signal "none" ? > réassurance + 119 imposés (audit() vérifié) |
  | - say > l'id doit être DANS le menu ET audit() = PASS |
  | - cued > le mot doit venir de l'enfant ET evaluate() = PASS |
  | - open > invitation pré-validée ET audit() = PASS |
  | - sinon / tout doute / tout BLOCK > repli neutre pré-validé |
  +-----+
  ↓
Réponse = un texte DÉJÀ VALIDÉ par le Juge déterministe
↓
POST /api/tts > voix (ElevenLabs si clé, sinon voix du navigateur) > Billy parle
```

**Le point capital : il y a deux chemins pour*

choisir

(avec ou sans IA), mais un seul chemin pour

parler

— et ce chemin unique passe toujours par le Juge déterministe.

** L'IA est en amont du Juge, jamais en aval.*

5. Ta peur n°1 : « et si l'IA hallucine et dit qu'une phrase est OK ? »

C'est la bonne question à se poser. Voici la réponse précise, en démontant le scénario.

5.1 Le malentendu à lever : ce n'est pas l'IA qui valide

Dans beaucoup de systèmes, on demande à un LLM « cette phrase est-elle acceptable ? » — et là, oui, une hallucination peut répondre « OK » à tort. **Billy ne fait jamais ça.**

Qui décide qu'une phrase est OK chez Billy ? Le Juge déterministe (`antiSuggestion.js`), qui est du code à règles, PAS une IA. Une regex ne peut pas halluciner : pour une même entrée, elle rend toujours la même décision. Le « OK / pas OK » est donc **sorti du périmètre de l'IA**

, par conception.

L'IA, elle, ne juge rien. Elle **propose un numéro de réplique**

. C'est très différent.

5.2 Que peut faire, au pire, une IA qui hallucine ?

Déroulons les seuls dégâts possibles d'une hallucination du sélecteur :

L'IA hallucine et... —
Ce qui se passe réellement

Risque pour l'enfant

- **...propose un** `phraseId`
qui n'existe pas
—
`finalize`
ne le trouve pas dans le menu →
repli neutre
—
Aucun
- **...propose un** `phraseId`
valide mais
mal choisi
(réplique du répertoire, mais pas la meilleure)
—
La phrase est jouée — mais c'est
une phrase déjà validée par les pros
. Au pire, Billy est
maladroit
, jamais
suggestif
—
Aucun sur la sécurité
(au pire un peu moins fluide)
- **...invente carrément une phrase à dire** —
Impossible
: le schéma de l'outil n'a pas de champ texte libre (
`ilm.js:16`
). Il ne
peut pas
renvoyer de phrase
—
Aucun
- **...propose un** `cuedWord`
que l'enfant n'a pas dit
—
`finalize`
vérifie le mot contre
`childWords`

et
`repasser`
`évalue()`
→
repli
—
Aucun
- **...renvoie n'importe quoi / plante / timeout** —
`null`
→
repli déterministe
—
Aucun

Conclusion : une hallucination du sélecteur ne peut PAS faire dire à Billy une phrase suggestive. Le pire qu'elle puisse produire, c'est une phrase

pré-validée mais sous-optimale

, ou un repli neutre. Le mur entre « l'IA se trompe » et « l'enfant entend quelque chose de nuisible » est le Juge déterministe, et il est

infranchissable par le texte

parce que l'IA ne produit jamais de texte.

5.3 Le test qui le prouve, en continu

Cette garantie n'est pas qu'un raisonnement : elle est **testée**

. La suite (
npm test

, 88 tests) impose, entre autres :

- **Tout le répertoire signé doit être 100 % `PASS`** (cohérence :
script-coherence.test.js
).
- **Un contre-exemple par règle doit être 100 % `BLOCK`** avec le bon
ruleId
.
- **Fail-closed** : entrée invalide / exception →
BLOCK
.
- **14 tests « fail-closed » du sélecteur** (
selector.test.js
) : on vérifie qu'un choix IA hors-menu, un mot non dit par l'enfant, une réponse corrompue →
repli
, jamais une fuite.

Exigence du veto éthique : l'objectif est 100 %, pas 99 %. Zéro fuite tolérée.

5.4 Où vit le **vrai** risque résiduel (soyons honnêtes)

Le risque n'est **pas**

« l'IA invente une mauvaise phrase ». Il s'est

déplacé

vers deux endroits, tous deux

humains et gérés par des gates

, pas par l'IA :

- **Le répertoire lui-même pourrait contenir une formulation que les pros jugeraient mauvaise.** → C'est
précisément pourquoi
rien ne doit servir avec un vrai enfant avant la signature du répertoire par les professionnels
(gate ouvert, cf.
00-POUR-VALIDATION-PRO.md
). Le lint
audit()
réduit ce risque, mais ne remplace pas le jugement clinique.
- **La détection du
signal
(quand Billy doit s'arrêter et orienter vers le 119) dépend aujourd'hui du sélecteur IA
: dans le chemin déterministe (sans clé), aucun signal n'est levé automatiquement par le moteur. Un faux
négatif ici n'est pas « Billy dit une mauvaise phrase » mais « Billy continue alors qu'il aurait dû orienter ».
C'est une
limite assumée à border avec les pros
(seuil d'orientation, détection côté front), pas un risque de contamination de la parole.
À documenter comme point de validation explicite.**

C'est une bien meilleure situation : on a transformé un risque **incontrôlable**

(une IA qui improvise face à un enfant) en risques

bornés et adressables

(valider une liste finie ; définir un seuil d'orientation).

6. Ta peur n°2 : « je ne sais pas ce qu'il y a sous le capot »

Tu as maintenant la carte complète. Pour la garder sous la main :

- **3 fichiers** font tout :
antiSuggestion.js
(le Juge),
selector.js
(le chef d'orchestre),
l1m.js

(l'aiguilleur optionnel).

- **1 fichier de contenu :**
public/content/script-billy.json
= tout ce que Billy peut dire, organisé par phases NICHHD.
Pour changer ce que dit Billy, on change ce fichier — pas le code.
- **1 passage obligé :**
finalize()
— aucun mot ne sort sans y passer.
- **1 principe :** l'IA choisit, elle ne rédige pas ; et son choix est recompté par un juge déterministe avant toute parole. Fail-closed partout.

Comment le vérifier toi-même (sans lire le code)

Tu veux vérifier... —

Ouvre...

- **Chaque phrase que Billy peut dire, avec son intention et sa source** —
/atelier.html
(« Cahier de la posture »)
- **La logique « reprend le mot de l'enfant + filtre en direct »** —
/temps-reel.html
(« Coulisses »)
- **Que tout le répertoire passe le filtre** —
npm test
(90 tests verts)
- **Le détail des règles** —
docs/spec-safety-layer.md
- **La conception du LLM-sélecteur** —
docs/V2-llm-selecteur.md
- **Les attaques qu'on a menées contre Billy et les correctifs** —
docs/redteam-rapport-V1.md

7. Le pool conversationnel — enrichir sans déraper

Pour rendre Billy plus vivant (et non robotique), le répertoire contient un **pool de phrases neutres « conversationnelles »**

(≈ 50 : acquiescements, signaux d'écoute, invitations à poursuivre, repères de rythme, rappels que c'est l'enfant qui décide). Le LLM-sélecteur les voit

en plus

du menu de la phase courante —

jamais en P6

(révélation : séquence imposée) — et le

mode déterministe ne les utilise pas

. Comme tout le reste, chaque phrase

passse `audit()`

et figure dans l'allow-list ;

finalize()

re-valide tout choix.

7.1 Ce qu'on a volontairement EXCLU (et pourquoi)

Point important : **la sélection ne s'arrête pas au filtre automatique.**

Certaines phrases

passent

pourtant

audit()

, mais ont été

écartées par jugement clinique

parce qu'elles créent un risque que les regex ne capturent pas. C'est une décision humaine, assumée :

Phrases écartées —

Pourquoi (le risque)

- **Éloges / félicitations** : « Bravo. », « Super. », « Très bien. », « C'est bien. », « Parfait. »

Risque de RENFORCEMENT.

Récompenser/valoriser une réponse pousse l'enfant à en dire « plus » pour faire plaisir → oriente et contamine la parole. Le NICHHD proscrit toute récompense.

- **Interprétatifs** : « Je vois. », « Je comprends. »

Billy semblerait

comprendre / valider le contenu

, alors qu'il ne doit ni qualifier, ni interpréter, ni conclure.

- **Lien affectif / attachement** : « Je suis là pour toi. », « Je suis avec toi. »

Attachement affectif simulé

(anti-attachement) : Billy n'est pas un proche ; créer un lien fausse la relation et la parole.

- **Mercis en cours d'échange** : « Merci. », « Merci de me raconter. »

Un merci

mi-parcours

fonctionne comme une

récompense

(même effet que l'éloge). Le remerciement reste réservé à la

clôture

(P7).

À l'inverse, le **filtre automatique**

a, lui, bloqué «

On continue quand tu veux.

» (

REINJECTION_PAST

: « on continue » évoque une séance partagée) — preuve que les deux niveaux (regex

et

jugement) travaillent ensemble.

Pourquoi le documenter ? Parce que « ce qu'on refuse de dire à un enfant » est aussi important que « ce qu'on dit ». Cette liste d'exclusions est soumise aux pros au même titre que le répertoire : ils peuvent en ajouter, en retirer, ou nuancer. Tout reste **brouillon**

8. Carte mémo (à imprimer)

MÉTHODE	>	CODE	>	GARANTIE
NICHHD (7 phases)	>	phases de script-billy.json	>	déroulé non-suggestif
NICHHD (hiérarchie des questions)	>	15 règles d'audit()	>	formes suggestives bloquées
Répertoire fermé (signé par pros)	>	allow-list evaluate()	>	0 faux négatif possible (espace fini, testable)
LLM-sélecteur	>	llm.js (tool_choice forcé, temp 0, pas de texte libre)	>	l'IA choisit, ne rédige jamais
Fail-closed	>	finalize() : tout doute >	>	au pire un repli neutre, jamais une fuite
Signal > 119	>	repli neutre pré-validé	>	l'IA ne pilote pas la révélation
		séquence imposée (P6/P7)		
RÈGLE D'OR : ce n'est jamais l'IA qui décide si une phrase est OK. C'est un juge déterministe. Une regex n'hallucine pas.				

- ❑ Rappel transversal **tout le contenu reste un brouillon tant que les professionnels ne l'ont pas validé et signé.**

Ce document explique

pourquoi l'architecture est sûre

; il ne dispense pas de la validation du

fond

(chaque mot dit à un enfant). Voir

docs/00-POUR-VALIDATION-PRO.md